

Rapport d'Avancement

Laura Cohen

Encadré par Johanne Cohen
LISN

Mai 2026

Table des matières

1	Introduction et Problématique	2
2	Analyse Micro : Tests Locaux et Explicabilité	3
3	Analyse Macro : Scalabilité et Découverte Causale Globale	5
	Références	8
A	Annexes techniques	9
B	Résumés de papiers clés	11

1 Introduction et Problématique

1.1 Le cadre formel de Pearl

La causalité, au sens de Judea Pearl, est axiomatisée par les Modèles Causaux Structurels (SCM) (Pearl, 2009). Un SCM est un triplet $\mathcal{M} = \langle \mathbf{U}, \mathbf{V}, \mathcal{F} \rangle$ où $\mathbf{U}$ est l'ensemble des variables exogènes (bruits), $\mathbf{V} = \{V_1, \dots, V_p\}$ l'ensemble des variables endogènes observées, et $\mathcal{F} = \{f_i\}_{i=1}^p$ un ensemble de fonctions structurelles telles que :

$$V_i := f_i(\text{Pa}(V_i), U_i), \quad i = 1, \dots, p, \quad (1)$$

où $\text{Pa}(V_i) \subseteq \mathbf{V} \setminus \{V_i\}$ désigne l'ensemble des parents causaux directs de V_i dans le DAG $\mathcal{G}$ associé au modèle. L'acyclicité de $\mathcal{G}$ garantit l'existence d'un unique ordre topologique sur $\mathbf{V}$, ce qui rend le modèle bien posé et permet de définir sans ambiguïté la notion de résidu de régression qui sera centrale dans notre algorithme.

Pearl (2009) formalise une hiérarchie épistémologique à trois niveaux, chacun strictement plus expressif que le précédent :

- (i) **Niveau observationnel** : $\mathbb{P}(Y \mid X = x)$, conditionnement sur des événements observés.
- (ii) **Niveau interventionnel** : $\mathbb{P}(Y \mid \text{do}(X = x))$, distribution de Y après intervention sur X , supprimant les arêtes entrantes de X dans $\mathcal{G}$.
- (iii) **Niveau contrefactuel** : $\mathbb{P}(Y_x = y \mid X = x', Y = y')$, raisonnement sur des mondes possibles.

C'est au niveau interventionnel que se situe l'enjeu applicatif de ce travail : décider d'investir dans l'électricité plutôt que dans l'Internet nécessite de connaître $\mathbb{P}(\text{résultat} \mid \text{do}(\text{électricité}))$, et non simplement la corrélation observationnelle. Or ce passage du conditionnement à l'intervention n'est possible que si l'on dispose du graphe causal $\mathcal{G}$.

La découverte causale consiste précisément à reconstruire $\mathcal{G}$ (ou sa classe d'équivalence de Markov, le MEC) à partir de la seule distribution observationnelle $\mathbb{P}(\mathbf{V})$. Cette tâche est fondamentalement sous-déterminée : deux DAG $\mathcal{G}$ et $\mathcal{G}'$ sont équivalents au sens de Markov s'ils partagent le même squelette et les mêmes v-structures, et sont donc indiscernables sans hypothèse supplémentaire (Spirtes et al., 2000). L'hypothèse de fidélité stipule que toute indépendance conditionnelle vérifiée dans $\mathbb{P}(\mathbf{V})$ est entièrement expliquée par les d-séparations dans $\mathcal{G}$, établissant ainsi un pont entre les propriétés du graphe et celles de la distribution observée.

1.2 Données et défis statistiques

Ce cadre théorique, bien que puissant, se heurte à des difficultés pratiques considérables dès que la dimension et l'hétérogénéité des données augmentent. Les expérimentations reposent sur les données de l'éducation brésilienne sur 10 ans, État de São Paulo, qui illustrent ces difficultés :

Haute dimensionnalité. $p = 300$ variables, $n \approx 220\,000$ observations. La complexité des tests d'indépendance conditionnelle d'ordre k croît en $\mathcal{O}(\binom{p}{k}n^2)$, prohibitif dès $k \geq 3$.

Hétérogénéité des types. Coexistent des variables catégorielles ordinales, des variables continues, et de nombreux indicateurs binaires. Cette hétérogénéité interdit l'utilisation naïve de tests paramétriques fondés sur la normalité.

Non-linéarité probable. Les dépendances entre infrastructures et résultats éducatifs ne peuvent être supposées linéaires a priori, ce qui invalide les tests fondés sur la corrélation de Pearson et motive le recours à des critères à noyaux (Gretton et al., 2007).

Ces trois contraintes (dimensionnalité, hétérogénéité, non-linéarité) structurent l'ensemble des choix méthodologiques présentés dans ce rapport.

1.3 Organisation du rapport

Pour répondre simultanément à ces trois défis, le projet s’articule autour de deux axes :

- A1. Analyse micro.** Avant de reconstruire un graphe global, il faut disposer de tests d’indépendance fiables entre paires de variables. Cet axe compare Pearson, MI-KSG (Kraskov et al., 2004) et HSIC (Gretton et al., 2007), et explore l’interface XAI SHAP (Shapley, 1953), LIME (Ribeiro et al., 2016), LASSO (Tibshirani, 1996), comme estimateur de l’indépendance conditionnelle et outil d’orientation des arêtes.
- A2. Analyse macro.** Une fois les briques locales établies, cet axe adresse le passage à l’échelle : clustering causal pour réduire la dimension effective (Anand et al., 2023), puis découverte causale globale via l’algorithme REX avec stabilisation bootstrap et extension non linéaire REX-HSIC (Hoyer et al., 2009).

Ces deux axes ne sont pas indépendants : les tests d’indépendance de l’axe micro sont précisément ceux utilisés dans le clustering causal de l’axe macro, et la mesure HSIC développée localement est réutilisée dans REX-HSIC pour lever l’hypothèse de linéarité.

2 Analyse Micro : Tests Locaux et Explicabilité

2.1 Indépendance statistique vs. indépendance causale

Le premier enjeu de l’analyse locale est de distinguer rigoureusement indépendance statistique et non-causalité.

Définition 2.1 (Indépendance statistique). *Deux variables X, Y sont statistiquement indépendantes, noté $X \perp\!\!\!\perp Y$, si et seulement si :*

$$\mathbb{P}(X, Y) = \mathbb{P}(X) \mathbb{P}(Y).$$

Sous l’hypothèse de fidélité (Spirtes et al., 2000), $X \perp\!\!\!\perp Y \mid \mathbf{Z}$ dans la distribution implique que tout chemin entre X et Y dans $\mathcal{G}$ est d-séparé par $\mathbf{Z}$. Cependant, la réciproque n’est pas garantie en pratique : une décision d’indépendance issue d’un test statistique peut refléter un faux négatif lié à une taille d’échantillon insuffisante ou à un choix de statistique inadapté à la structure de dépendance réelle. C’est pourquoi le choix du test d’indépendance n’est pas anodin, et fait l’objet de la comparaison systématique de la section suivante.

2.2 Tests d’indépendance : formalisation

Nous comparons trois familles de tests, ordonnées par expressivité croissante et coût computationnel croissant.

Coefficient de Pearson.

$$\hat{r} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}}. \quad (2)$$

Sous $H_0 : \rho = 0$ et normalité bivariée, $t = \hat{r} \sqrt{(n-2)/(1-\hat{r}^2)} \sim t_{n-2}$. Ce test est aveugle à toute structure non linéaire : si $Y = X^2$ avec $X \sim \mathcal{N}(0, 1)$, alors $\hat{r} \xrightarrow{p} 0$ malgré une dépendance fonctionnelle exacte. Cette limitation le rend insuffisant pour nos données, ce qui motive le recours à des estimateurs non paramétriques.

Information mutuelle et estimateur KSG. L’information mutuelle répond à cette limitation en mesurant toute forme de dépendance (Kraskov et al., 2004) :

$$I(X; Y) = \iint p(x, y) \log \frac{p(x, y)}{p(x)p(y)} dx dy = D_{\text{KL}}(\mathbb{P}_{XY} \parallel \mathbb{P}_X \otimes \mathbb{P}_Y). \quad (3)$$

En pratique, les densités $p(x, y)$ sont inconnues et doivent être estimées. L’estimateur KSG à k plus proches voisins évite cette estimation explicite :

$$\hat{I}_{\text{KSG}}(X; Y) = \psi(k) - \frac{1}{n} \sum_{i=1}^n [\psi(n_x(i) + 1) + \psi(n_y(i) + 1)] + \psi(n), \quad (4)$$

où ψ est la fonction digamma.

HSIC : critère à noyaux. Pour disposer à la fois d’un test universel et d’un cadre théorique solide, nous adoptons l’HSIC (Gretton et al., 2007). Soient $\mathcal{H}_X, \mathcal{H}_Y$ deux RKHS associés aux noyaux k_X, k_Y . L’opérateur de covariance croisée $C_{XY} : \mathcal{H}_Y \rightarrow \mathcal{H}_X$ vérifie $\langle f, C_{XY}g \rangle = \mathbb{E}[f(X)g(Y)] - \mathbb{E}[f(X)]\mathbb{E}[g(Y)]$. L’HSIC est la norme de Hilbert-Schmidt de cet opérateur :

$$\text{HSIC}(X, Y) := \|C_{XY}\|_{\text{HS}}^2 = \frac{1}{(n-1)^2} \text{Tr}(K_X H K_Y H), \quad (5)$$

où $H = I_n - \frac{1}{n} \mathbf{1}\mathbf{1}^\top$ est la matrice de centrage. La propriété clé est que si k_X est caractéristique (RBF, Laplace), alors $\text{HSIC}(X, Y) = 0 \Leftrightarrow X \perp\!\!\!\perp Y$ (voir la preuve complète en Annexe A). Cela en fait un test d’indépendance universel et exact, au prix d’une complexité quadratique discutée ci-dessous.

Noyaux implémentés. Quatre noyaux ont été intégrés, couvrant des profils de dépendance différents :

- **Linéaire** : $k(x, x') = x^\top x'$: récupère la covariance classique.
- **RBF** : $k(x, x') = \exp(-\|x - x'\|_2^2 / 2\sigma^2)$: universel sur $\mathbb{R}^d$.
- **Polynomial** : $k(x, x') = (x^\top x' + c)^d$: interactions d’ordre $\leq d$.
- **Laplace** : $k(x, x') = \exp(-\|x - x'\|_1 / \sigma)$: robuste aux queues lourdes, adapté aux distributions asymétriques présentes dans nos données (effectifs, ratios).

2.3 Analyse comparative et complexité

Le tableau suivant synthétise les propriétés des trois familles de tests. Le choix pratique dépend du compromis entre puissance statistique, expressivité, et coût.

TABLE 1 – Comparaison des tests d’indépendance.

Méthode	Hypothèse	Complexité	Remarques
Pearson $\hat{r}$	Linéaire	$\mathcal{O}(n)$	Test t exact sous normalité
MI-KSG (Kraskov et al., 2004)	Quelconque	$\mathcal{O}(n \log n)$	Biais $\mathcal{O}(1/n)$
HSIC linéaire (Gretton et al., 2007)	Linéaire	$\mathcal{O}(n^2)$	$= \text{Cov}(k_X, k_Y)$
HSIC RBF (Gretton et al., 2007)	Quelconque	$\mathcal{O}(n^2)$	Noyau universel
HSIC Laplace (Gretton et al., 2007)	Quelconque	$\mathcal{O}(n^2)$	Robuste aux queues lourdes

La contrainte principale de l’HSIC est sa complexité mémoire quadratique : pour $n = 220\,000$, la matrice de Gram requiert ~ 296 Go. Deux stratégies sont envisagées : l’approximation de Nyström (Rahimi and Recht, 2007), qui réduit la complexité à $\mathcal{O}(nm)$ avec $m \ll n$ points représentatifs, et le sous-échantillonnage ($n' = 5\,000$). Ces deux approches sont détaillées en Annexe A.

2.4 Robustesse et validation

La puissance d'un test étant une condition nécessaire mais non suffisante à sa fiabilité, deux procédures complémentaires sont mises en place pour valider les décisions d'indépendance.

1. **Permutation sauvage.** Sous H_0 , permuter les indices de Y détruit la dépendance tout en préservant les marginales, fournissant une distribution nulle empirique sans hypothèse distributionnelle. La p-valeur conservative :

$$\hat{p} = \frac{1 + \#\{b : \widehat{\text{HSIC}}^{(b)} \geq \widehat{\text{HSIC}}_{\text{obs}}\}}{B + 1}$$

garantit le contrôle du risque de première espèce à tout niveau α (voir Annexe A pour la justification).

2. **Analyse de sensibilité.** Un bruit additif $\delta \sim \mathcal{N}(0, \tau^2 I)$ pour $\tau \in \{0.01, 0.05, 0.10\} \cdot \hat{\sigma}_X$ est injecté dans les données. Une forte variance de la p-valeur résultante signale une décision instable.

2.5 Méthodes d'Explicabilité (XAI) et Indépendance Causale

2.5.1 De l'explicabilité à l'indépendance conditionnelle

Parallèlement aux tests d'indépendance classiques, une deuxième approche exploite les outils d'explicabilité des modèles prédictifs. Un modèle optimal $f = \mathbb{E}[Y \mid \mathbf{V} \setminus \{Y\}]$ encèle implicitement toutes les indépendances conditionnelles dans ses scores d'importance. Plus précisément, si la contribution de X_j à la prédiction est nulle pour toute instance x , alors nécessairement $X_j \perp\!\!\!\perp Y \mid \mathbf{V} \setminus \{Y, X_j\}$. Les méthodes XAI deviennent ainsi un oracle d'indépendance conditionnelle sans spécifier de test paramétrique, ce qui les rend attrayantes dans notre contexte hétérogène.

2.5.2 Valeurs de Shapley (SHAP)

Les valeurs SHAP (Shapley, 1953), issues de la théorie des jeux coopératifs, sont l'unique allocation satisfaisant simultanément efficience ($\sum_j \phi_j = f(x) - \mathbb{E}[f]$), symétrie, linéarité et élément nul :

$$\phi_j(f, \mathbf{x}) = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [f_{\mathbf{x}}(S \cup \{j\}) - f_{\mathbf{x}}(S)], \quad (6)$$

où $f_{\mathbf{x}}(S) := \mathbb{E}[f(\mathbf{X}) \mid \mathbf{X}_S = \mathbf{x}_S]$. Intuitivement, ϕ_j mesure la contribution marginale moyenne de X_j , pondérée sur toutes les coalitions possibles.

Au-delà du test d'indépendance, SHAP offre une piste pour l'orientation des arêtes via l'asymétrie $\phi_j^{Y \leftarrow X} \neq \phi_j^{X \leftarrow Y}$: la cause tend à avoir une contribution plus stable que l'effet. Cette heuristique, discutée dans le cadre des Causal Shapley Values par Heskes et al. (2020), n'est pas un théorème général et doit impérativement être couplée avec des tests d'indépendance pour neutraliser la multicollinéarité.

3 Analyse Macro : Scalabilité et Découverte Causale Globale

Les outils développés dans la section précédente permettent de tester l'indépendance entre paires de variables. La difficulté fondamentale est de les combiner pour reconstruire un graphe global sur $p = 300$ variables sans que la complexité ne devienne prohibitive. Cette section présente une stratégie en deux étapes : réduire d'abord la dimension par clustering causal, puis appliquer un algorithme de découverte causale sur les macro-variables résultantes.

3.1 Complexité combinatoire des algorithmes de type PC

Pour bien situer la difficulté, rappelons que l’algorithme PC (Spirtes et al., 2000), la référence dans la catégorie des approches par contraintes, procède par tests d’indépendance conditionnelle d’ordre croissant. Le nombre de tests à l’ordre k est borné par $\binom{p}{2} \binom{p-2}{k}$, soit $\mathcal{O}(p^{k+2}/k!)$. Pour $p = 300$ et $k = 3$: $\approx 6.5 \times 10^8$ tests, chacun de coût $\mathcal{O}(n^2)$ pour l’HSIC : une complexité globale totalement rédhibitoire. Cette observation motive directement la stratégie de clustering présentée ci-après.

3.2 Clustering causal de variables

L’idée centrale, proposée par Anand et al. (2023), est d’exploiter la structure de dépendance bivariée pour regrouper les variables avant d’appliquer un algorithme de découverte causale. La procédure comporte quatre étapes :

1. **Matrice de distance d’indépendance.** Pour toute paire (i, j) :

$$d_{ij} = 1 - \frac{\widehat{\text{HSIC}}(V_i, V_j)}{\sqrt{\widehat{\text{HSIC}}(V_i, V_i) \widehat{\text{HSIC}}(V_j, V_j)}}.$$

. Les variables fortement dépendantes se retrouvent proches dans cet espace.

2. **Clustering hiérarchique ou spectral.** Un algorithme de clustering sur la matrice $D = (d_{ij})$ produit $K \ll p$ clusters $\mathcal{C}_1, \dots, \mathcal{C}_K$, avec $K \approx 10\text{-}20$ déterminé par des critères de cohérence interne.
3. **Représentation.** Chaque cluster $\mathcal{C}_k$ est résumé par $\tilde{V}_k = \text{PC}_1(\{V_i : i \in \mathcal{C}_k\})$, sa première composante principale.
4. **Découverte inter-clusters.** L’algorithme REX est appliqué sur le système réduit $(\tilde{V}_1, \dots, \tilde{V}_K)$.

3.3 Algorithme REX

Une fois la dimension réduite, nous appliquons l’algorithme REX (*Residual Expression causal discovery*), qui exploite l’asymétrie fondamentale des résidus de régression dans un SCM linéaire additif. Si X_i est une racine (sans parents), ses résidus de régression sur n’importe quelle autre variable sont indépendants d’elle-même, car X_i n’est influencée par aucune variable cachée. Le score de résidus formalise cette observation :

$$s(i) = \sum_{j \in \mathcal{R} \setminus \{i\}} \left| \text{Corr}(X_i, X_j - \hat{b}_{ji} X_i) \right|, \quad (7)$$

où $\hat{b}_{ji} = \text{Cov}(X_i, X_j) / \text{Var}(X_i)$. La racine est $i^* = \arg \min_{i \in \mathcal{R}} s(i)$; la preuve de cohérence est donnée en Annexe A.

Algorithm 1 REX

Require: Matrice $X \in \mathbb{R}^{n \times p}$, seuil $\tau > 0$

Ensure: Ordre topologique π , matrice $\hat{B}$

```
1:  $\mathcal{R} \leftarrow \{1, \dots, p\}$ ,  $\pi \leftarrow ()$ 
2: while  $\mathcal{R} \neq \emptyset$  do
3:   for chaque  $i \in \mathcal{R}$  do
4:     Calculer  $s(i)$  selon (7)
5:   end for
6:    $i^* \leftarrow \arg \min_{i \in \mathcal{R}} s(i)$ ; ajouter  $i^*$  à  $\pi$ ;  $\mathcal{R} \leftarrow \mathcal{R} \setminus \{i^*\}$ 
7:   for chaque  $j \in \mathcal{R}$  do
8:      $X_j \leftarrow X_j - \hat{b}_{ji^*} X_{i^*}$  ▷ Orthogonalisation : retire l'influence de  $i^*$ 
9:   end for
10: end while
11: Estimer  $\hat{B}$  par régression; élaguer :  $\hat{B}_{kl} \leftarrow 0$  si  $|\hat{B}_{kl}| < \tau$ 
```

L'étape d'orthogonalisation est cruciale : en retirant la contribution de la racine trouvée avant l'itération suivante, elle permet de chercher la racine du sous-graphe résiduel plutôt que du graphe original. La complexité totale est $\mathcal{O}(p^3 \cdot n)$.

3.4 Stabilisation par bootstrap

REX, comme tout algorithme de découverte causale, est sensible aux fluctuations échantillonales. Pour filtrer ces instabilités, nous stabilisons les résultats par bootstrap causal.

Principe. On génère M versions légèrement différentes du jeu de données en tirant n observations avec remise, on applique REX sur chacune, et on observe quelles arêtes apparaissent systématiquement. Une arête qui survit sur la grande majorité des réplicats est robuste ; une arête qui n'apparaît qu'une fois sur deux est vraisemblablement due au hasard.

Définition 3.1 (Bootstrap causal). *Soit $\hat{B}^{(b)}$ la matrice structurelle estimée par REX sur le b -ième réplicat bootstrap, où $\hat{B}_{kl}^{(b)} \neq 0$ signifie que l'arête $k \rightarrow l$ est présente dans ce réplicat. La fréquence de stabilité de l'arête $k \rightarrow l$ est la proportion de réplicats où elle apparaît :*

$$\hat{q}_{kl} = \frac{1}{M} \sum_{b=1}^M \mathbb{1}[\hat{B}_{kl}^{(b)} \neq 0].$$

On ne retient dans le DAG final que les arêtes vérifiant $\hat{q}_{kl} \geq q_{\min}$ (typiquement $q_{\min} = 0.70$).

3.5 Extension non linéaire : REX-HSIC

L'hypothèse de linéarité de REX constitue sa principale limitation. Pour la lever, nous proposons REX-HSIC, qui remplace la corrélation des résidus par HSIC (Gretton et al., 2007) ; le critère universel développé en Section 2 :

$$\tilde{s}(i) = \sum_{j \in \mathcal{R} \setminus \{i\}} \widehat{\text{HSIC}}(X_i, X_j - \hat{f}_{ji}(X_i)), \quad (8)$$

où $\hat{f}_{ji}$ est un estimateur non paramétrique (processus gaussien ou forêt aléatoire) de $\mathbb{E}[X_j | X_i]$. Cette extension est théoriquement consistante sous les hypothèses des modèles additifs non linéaires (Hoyer et al., 2009), et constitue le prolongement naturel de ce travail vers une découverte causale véritablement non linéaire et scalable.

Références

Références

- Anand, T. V., Ribeiro, A. H., Tian, J., Hripcsak, G., and Bareinboim, E. (2023). Causal discovery over clusters of variables in Markovian systems.
- Even-Zohar, C. (2021). independence : Fast rank tests. *Journal of Computational and Graphical Statistics*.
- Gretton, A., Fukumizu, K., Teo, C. H., Song, L., Schölkopf, B., and Smola, A. J. (2007). A kernel statistical test of independence. In *Advances in Neural Information Processing Systems (NeurIPS)*
- Heskes, T., Sijben, E., Bucur, I. G., and Claassen, T. (2020). Causal Shapley values : Exploiting causal knowledge to explain individual predictions of complex models. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- Hoyer, P. O., Janzing, D., Mooij, J. M., Peters, J., and Schölkopf, B. (2009). Nonlinear causal discovery with additive noise models. In *Advances in Neural Information Processing Systems (NeurIPS)*
- Janzing, D. et al. (2012). Information-geometric approach to inferring causal directions. *Artificial Intelligence*
- Kraskov, A., Stögbauer, H., and Grassberger, P. (2004). Estimating mutual information. *Physical Review E*
- Pearl, J. (2009). *Causality : Models, Reasoning, and Inference*. Cambridge University Press, 2nd edition.
- Rahimi, A. and Recht, B. (2007). Random features for large-scale kernel machines. In *Advances in Neural Information Processing Systems (NeurIPS)*
- Ribeiro, M. T., Singh, S., and Guestrin, C. (2016). “Why should I trust you?” : Explaining the predictions of any classifier. In *Proceedings of the 22nd ACM SIGKDD*
- Shapley, L. S. (1953). A value for n -person games. In Kuhn, H. and Tucker, A., editors, *Contributions to the Theory of Games*,
- Spirtes, P., Glymour, C., and Scheines, R. (2000). *Causation, Prediction, and Search*. MIT Press, 2nd edition.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society*

A Annexes techniques

A.1 LIME

Contrairement à SHAP qui fournit une explication globale, LIME (Ribeiro et al., 2016) approxime f localement autour d’une instance $\mathbf{x}$ par un modèle linéaire interprétable :

$$g^* = \arg \min_{g \in \mathcal{G}} \mathcal{L}(f, g, \pi_{\mathbf{x}}) + \Omega(g), \quad (9)$$

où $\pi_{\mathbf{x}}(z) = \exp(-D(\mathbf{x}, z)^2/\sigma^2)$ pondère les points par leur proximité à $\mathbf{x}$ et $\Omega(g)$ pénalise la complexité du modèle local.

A.2 Régularisations LASSO et Ridge

Lorsqu’on se restreint au cadre linéaire, les régularisations offrent une alternative plus simple et plus rapide. Le LASSO (Tibshirani, 1996) fournit un test d’indépendance conditionnelle linéaire :

$$\hat{\beta}^{\text{LASSO}} = \arg \min_{\beta} \frac{1}{2n} \|y - X\beta\|_2^2 + \lambda \|\beta\|_1. \quad (10)$$

$\hat{\beta}_j = 0$ si et seulement si la contribution marginale de X_j est inférieure au seuil λ conditionnellement aux autres variables. En présence de forte collinéarité, la pénalité Ridge s’impose :

$$\hat{\beta}^{\text{Ridge}} = (X^\top X + \lambda I)^{-1} X^\top y, \quad (11)$$

qui contrôle la variance des estimateurs au prix d’un biais systématique. Dans notre pipeline, LASSO et Ridge servent de pré-filtrage rapide avant d’appliquer HSIC sur les paires candidates.

A.3 RKHS et noyaux caractéristiques

Définition A.1 (Espace de Hilbert à noyau reproduisant). *Un espace de Hilbert $\mathcal{H}$ de fonctions $f : \mathcal{X} \rightarrow \mathbb{R}$ est un RKHS associé au noyau $k : \mathcal{X} \times \mathcal{X} \rightarrow \mathbb{R}$ si :*

1. *Pour tout $x \in \mathcal{X}$, la fonction $k(\cdot, x) \in \mathcal{H}$.*
2. **Propriété de reproduction** : $\forall f \in \mathcal{H}, f(x) = \langle f, k(\cdot, x) \rangle_{\mathcal{H}}$.

Définition A.2 (Noyau caractéristique). *Un noyau k est caractéristique si l’application $\mu_k : \mathcal{P}(\mathcal{X}) \rightarrow \mathcal{H}$, définie par $\mu_k(\mathbb{P}) = \mathbb{E}_{X \sim \mathbb{P}}[k(\cdot, X)]$, est injective : $\mu_k(\mathbb{P}) = \mu_k(\mathbb{Q}) \Rightarrow \mathbb{P} = \mathbb{Q}$.*

Proposition A.1. *Les noyaux RBF et Laplace sont caractéristiques sur $\mathbb{R}^d$.*

A.4 Preuve complète du théorème HSIC

Théorème A.1 (Caractérisation HSIC, Gretton et al. 2007). *Soient k_X et k_Y des noyaux mesurables bornés. Alors $\text{HSIC}(\mathbb{P}_{XY}; k_X, k_Y) := \|C_{XY}\|_{\text{HS}}^2 \geq 0$, avec égalité si et seulement si $X \perp\!\!\!\perp Y$, pourvu que k_X ou k_Y soit caractéristique.*

Démonstration. Étape 1 : Développement de la norme HS. Si $\{e_i\}$ et $\{f_j\}$ sont des bases orthonormées de $\mathcal{H}_X$ et $\mathcal{H}_Y$:

$$\|C_{XY}\|_{\text{HS}}^2 = \sum_{i,j} (\mathbb{E}[e_i(X)f_j(Y)] - \mathbb{E}[e_i(X)]\mathbb{E}[f_j(Y)])^2.$$

Étape 2 : Expression via les noyaux.

$$\begin{aligned}\|C_{XY}\|_{\text{HS}}^2 &= \mathbb{E}_{XX'YY'}[k_X(X, X')k_Y(Y, Y')] + \mathbb{E}_{XX'}[k_X(X, X')] \mathbb{E}_{YY'}[k_Y(Y, Y')] \\ &\quad - 2 \mathbb{E}_{XY}[\mathbb{E}_{X'}[k_X(X, X')] \mathbb{E}_{Y'}[k_Y(Y, Y')]].\end{aligned}$$

Étape 3 : $\text{HSIC} = 0 \Leftrightarrow X \perp\!\!\!\perp Y$. Si $X \perp\!\!\!\perp Y$, chaque terme se factorise et $\|C_{XY}\|_{\text{HS}}^2 = 0$. Réciproquement, si $C_{XY} = 0$, alors pour toute $f \in \mathcal{H}_X$ et $g \in \mathcal{H}_Y$: $\mathbb{E}[f(X)g(Y)] = \mathbb{E}[f(X)]\mathbb{E}[g(Y)]$. Si k_X est caractéristique, $\mathcal{H}_X$ est dense dans $C_0(\mathcal{X})$. Par un argument de classe monotone, l'égalité s'étend à toutes les fonctions mesurables bornées, impliquant $\mathbb{P}_{XY} = \mathbb{P}_X \otimes \mathbb{P}_Y$. $\square$

Étape 4 : Estimateur empirique. Pour n observations (x_i, y_i) :

$$\widehat{\text{HSIC}}(X, Y) = \frac{1}{(n-1)^2} \text{Tr}(K_X H K_Y H), \quad (12)$$

où $H = I_n - n^{-1}\mathbf{1}\mathbf{1}^\top$. Forme développée (sans stocker H), avec $\bar{k}_X^{(i)} = n^{-1} \sum_j k_X(x_i, x_j)$ et $\bar{\bar{k}}_X = n^{-2} \sum_{i,j} k_X(x_i, x_j)$:

$$\widehat{\text{HSIC}}(X, Y) = \frac{1}{(n-1)^2} \left[\sum_{i,j} k_X(x_i, x_j) k_Y(y_i, y_j) - \frac{2}{n} \sum_i \bar{k}_X^{(i)} \bar{k}_Y^{(i)} \cdot n + n^2 \bar{\bar{k}}_X \bar{\bar{k}}_Y \right]. \quad (13)$$

A.5 Distribution nulle de HSIC et test asymptotique

Sous $H_0 : X \perp\!\!\!\perp Y$, Gretton et al. (2007) montrent que $(n-1)\widehat{\text{HSIC}} \xrightarrow{d} \sum_{l=1}^{\infty} \lambda_l (z_l^2 - 1)$, où λ_l sont les valeurs propres de l'opérateur intégral associé à $k_X \otimes k_Y$ et $z_l \sim \mathcal{N}(0, 1)$ i.i.d. Cette distribution est approchée par une loi Gamma $\Gamma(\alpha, \beta)$:

$$\alpha = \frac{(\mathbb{E}[\widehat{\text{HSIC}}])^2}{\text{Var}[\widehat{\text{HSIC}}]}, \quad \beta = \frac{n \cdot \text{Var}[\widehat{\text{HSIC}}]}{\mathbb{E}[\widehat{\text{HSIC}}]}.$$

A.6 Approximation de Nyström pour HSIC

La procédure de Nyström (Rahimi and Recht, 2007) approche $K \approx \tilde{\Phi} \tilde{\Phi}^\top$ avec $\tilde{\Phi} = K_{nm}(K_{mm})^{-1/2} \in \mathbb{R}^{n \times m}$, réduisant la complexité à $\mathcal{O}(nm)$. Les random Fourier features offrent une alternative : pour un noyau shift-invariant, par le théorème de Bochner :

$$k(x, x') \approx z(x)^\top z(x'), \quad z(x) = \sqrt{2/m} [\cos(\omega_1^\top x + b_1), \dots, \cos(\omega_m^\top x + b_m)],$$

où ω_j est échantillonné selon la transformée de Fourier de k .

A.7 Propriétés statistiques de l'estimateur KSG

L'estimateur KSG se réécrit $\hat{I}_{\text{KSG}} = \hat{H}(X) + \hat{H}(Y) - \hat{H}(X, Y)$ où chaque entropie est estimée par la méthode k -NN de Kozachenko-Leonenko (Kraskov et al., 2004). Le biais vérifie $\mathbb{E}[\hat{I}_{\text{KSG}}] = I(X; Y) + \mathcal{O}(k/n)$ et la variance $\text{Var}[\hat{I}_{\text{KSG}}] = \mathcal{O}(k^2/(n \log^2 k))$. Un k croissant lentement (typiquement $k = \lfloor n^{2/5} \rfloor$) minimise l'erreur quadratique moyenne.

A.8 Preuve de la cohérence de REX sous SCM linéaire

Proposition A.2 (Cohérence de REX). *Soit un SCM linéaire additif $X_j = \sum_{k \in \text{Pa}(j)} b_{jk} X_k + U_j$ avec bruits $\{U_j\}$ mutuellement indépendants, de variance non nulle, et tels qu'aucune cancellation accidentelle de coefficients ne se produise. Alors :*

(i) Si X_i est une racine, $s(i) = 0$.

(ii) Si X_i n'est pas une racine, $s(i) > 0$.

En particulier, $\arg \min_i s(i)$ identifie correctement une racine du DAG.

Démonstration. (i) Si X_i est une racine, $X_i = U_i$ avec $U_i \perp\!\!\!\perp \mathbf{V} \setminus \{X_i\}$. Le résidu de X_j sur X_i est $R_{ji} = X_j - \frac{\text{Cov}(X_i, X_j)}{\text{Var}(X_i)} X_i$. Par linéarité de la covariance :

$$\text{Cov}(X_i, R_{ji}) = \text{Cov}(X_i, X_j) - \frac{\text{Cov}(X_i, X_j)}{\text{Var}(X_i)} \text{Var}(X_i) = 0.$$

Donc $\text{Corr}(X_i, R_{ji}) = 0$ pour tout $j \neq i$, d'où $s(i) = 0$.

(ii) Admis. □

B Résumés de papiers clés

B.1 Causal Shapley Values (Heskes et al., 2020)

Idée principale. Heskes et al. (2020) remplacent l'espérance conditionnelle $\mathbb{E}[f \mid X_S = x_S]$ de SHAP par une espérance interventionnelle $\mathbb{E}[f \mid \text{do}(X_S = x_S)]$, décomposant la contribution de chaque variable en effet direct et effet indirect (via les médiateurs).

Formulation. Pour un DAG $\mathcal{G}$ connu :

$$\phi_j^{\text{causal}} = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(p - |S| - 1)!}{p!} [\mathbb{E}[f \mid \text{do}(X_{S \cup \{j\}} = x_{S \cup \{j\}})] - \mathbb{E}[f \mid \text{do}(X_S = x_S)]].$$

Limite et lien. La méthode suppose le DAG connu, ce que nous cherchons précisément à découvrir. Notre utilisation de SHAP comme proxy d'indépendance conditionnelle est plus heuristique mais ne requiert pas cette connaissance a priori.

B.2 Fast Rank Tests (Even-Zohar, 2021)

Idée principale. Even-Zohar (2021) observent que les statistiques de rang (Spearman, Hoeffding) s'écrivent comme des convolutions discrètes sur la grille des rangs, calculables par FFT en $\mathcal{O}(n \log n)$ au lieu de $\mathcal{O}(n^2)$.

Lien avec notre travail. Ces tests constituent une alternative à HSIC pour les tests bivariés dans le clustering causal : plus rapides ($\mathcal{O}(n \log n)$ vs $\mathcal{O}(n^2)$), non paramétriques, sans choix de noyau. Inconvénient : ne se généralisent pas directement aux tests d'indépendance conditionnelle.

B.3 HSIC comme test d'indépendance (Gretton et al., 2007)

2005. Établit que $\text{HSIC} = \|C_{XY}\|_{\text{HS}}^2$ et prouve la caractérisation (Théorème A.1) : $\text{HSIC} = 0 \Leftrightarrow X \perp\!\!\!\perp Y$ pour des noyaux caractéristiques. Démontre que HSIC généralise la corrélation canonique et la distance de corrélation.

2007. Dérive la distribution asymptotique de $(n-1)\widehat{\text{HSIC}}$ sous H_0 , approchée par une loi Gamma, et établit la convergence de l'estimateur à vitesse $\mathcal{O}(1/\sqrt{n})$. Propose le test par permutation comme alternative sur petits échantillons.

Contributions pour notre travail. La caractérisation universelle justifie le remplacement de Pearson dans les algorithmes causaux. L'estimateur $\frac{1}{(n-1)^2} \text{Tr}(K_X H K_Y H)$ est implémenté directement dans notre boîte à outils.