

Causal Discovery pour grands jeux de données

Tests d'indépendance et découverte causale à grande échelle

Laura COHEN

LISN – Laboratoire Interdisciplinaire des Sciences du Numérique
CentraleSupélec
Encadrante **Johanne Cohen**

Mai 2026


- 1 Contexte
- 2 État de l'art
- 3 Objectifs
- 4 Méthodologie
- 5 Algorithmes causaux
- 6 Perspectives
- 7 Conclusion

Motivation scientifique

- Les modèles statistiques classiques capturent des corrélations mais pas les relations causales.
- Les données observationnelles sont massives et hétérogènes : santé, finance, climat, réseaux.
- Les approches causales permettent une meilleure interprétabilité des décisions.

Applications

- Aide à la décision.
- Analyse de systèmes complexes.
- IA explicable et robustesse des modèles.



Exemple de graphe causal avec variable cachée.

- ❶ Développer une méthodologie scalable pour la découverte causale sur grands graphes.
- ❷ Comparer plusieurs tests d'indépendance :
 - Pearson
 - MI-KSG
 - HSIC
- ❸ Étudier leur impact sur les performances des algorithmes causaux.
- ❹ Étendre ces approches vers l'IA explicable pour réseaux de neurones.

Question de recherche :


Comment concevoir des méthodes de découverte causale robustes et interprétables pour des données de grande dimension ?

Tests comparés

- 1 **Pearson** : dépendances linéaires, coût faible.
- 2 **MI-KSG** : information mutuelle par k-plus proches voisins.
- 3 **HSIC** : dépendances non linéaires via noyaux RKHS.

Critères d'évaluation

- Robustesse au bruit
- Détection des non-linéarités
- Temps de calcul
- Scalabilité



- **Coefficient de Pearson (r)** : Mesure la corrélation linéaire.

$$\rho_{X,Y} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

- **Information Mutuelle (MI)** : Capture toute forme de dépendance.

$$I(X; Y) = \iint P(x, y) \log \left(\frac{P(x, y)}{P(x)P(y)} \right) dx dy$$

- **Hilbert-Schmidt Independence Criterion (HSIC)** : Basé sur les noyaux k_x, k_y dans des espaces RKHS.

$$\text{HSIC}(\mathbb{P}_{XY}) = \|C_{XY}\|_{HS}^2$$


Indépendance si et seulement si HSIC = 0 (pour des noyaux caractéristiques).

Performance vs Non-linéarité


- **Pearson** : Échoue sur les relations de type $Y = X^2$.
- **MI-KSG** : Robuste mais très lent sur grands N (recherche de voisins).
- **HSIC** : Excellent compromis, capture les structures complexes (sinusoïdes, cercles).

Résultat

HSIC identifie des liens causaux invisibles pour les méthodes linéaires.



Courbe de puissance : dépendance quadratique faible



Analyse de sensibilité ($Y = 0.3X^2 + \epsilon$)

- **Pearson (limitation)** : puissance quasi plate au niveau de $\alpha = 0.05$.
- **Seuil de 80 %** : nombre d'échantillons n requis pour obtenir un test fiable.
- **Scalabilité** : HSIC offre un excellent compromis puissance/temps de calcul.

Valeurs de Shapley pour l'attribution causale

On définit la contribution d'une variable i comme :

$$\phi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(n - |S| - 1)!}{n!} [v(S \cup \{i\}) - v(S)]$$

- **Problème** : Complexité exponentielle 2^p .
- **Solution** : Algorithme d'approximation par échantillonnage ou *KernelSHAP*.
- **Objectif** : Utiliser Shapley pour mesurer l'influence causale d'un parent sur son enfant dans un graphe.

LiNGAM

$$X = BX + \varepsilon$$

- Modèle linéaire non gaussien
- Identifiabilité complète
- Complexité élevée pour grand p

REX

$$X_j = f_j(X_{\text{pa}(j)}) + \varepsilon_j$$


- Approche randomisée
- Compatible avec les non-linéarités
- Meilleure scalabilité

Objectif expérimental

Comparer précision, robustesse et coût de calcul sur des graphes de tailles croissantes.

Graphe causal généré

DAG



Compétences développées

- Tests d'indépendance avancés
- Découverte causale à grande échelle
- Analyse expérimentale et benchmarking
- Première expérience de recherche scientifique