

Causal Discovery pour grands jeux de données

Tests d'indépendance et découverte causale à grande échelle

Laura Cohen

LISN - Laboratoire Interdisciplinaire des Sciences du Numérique
CentraleSupélec
Encadrante : **Johanne Cohen**

Mai 2026

- 1 Contexte et enjeux
- 2 État de l'art
- 3 Objectifs
- 4 Niveau Micro
- 5 Niveau Macro
- 6 Perspectives
- 7 Conclusion


La révolution de Pearl

Judea Pearl (Pearl, 2009) formalise une **hiérarchie épistémologique** à trois niveaux :

- 1 **Observation** : $\mathbb{P}(Y \mid X=x)$, voir
- 2 **Intervention** : $\mathbb{P}(Y \mid \text{do}(X=x))$, agir
- 3 **Contrefactuel** : $\mathbb{P}(Y_x \mid X=x')$, imaginer

Problème central

Corrélation $\neq$ causalité. Un modèle statistique ne peut pas, seul, distinguer une cause d'un simple symptôme. Or c'est précisément ce dont on a besoin pour décider et intervenir.



Accès Internet corrélé aux résultats scolaires.

La région est-elle un facteur confondant ?

Jeu de données : État de São Paulo (10 ans)

- $p = 300$ variables, $n \approx 220\,000$ observations
- Variables d'infrastructure, de ressources, etc.

Enjeux sociétaux

- Quelles infrastructures causent réellement une amélioration des résultats ?
- Orienter les politiques publiques d'investissement de façon rationnelle
- Éviter les faux leviers

Défis statistiques

Haute dim. Tests d'ordre k : $\mathcal{O}\left(\binom{p}{k} n^2\right)$, prohibitif dès $k \geq 3$

Hétérogénéité Variables ordinales, continues et binaires mélangées

Non-linéarité Dépendances non linéaires a priori

Question de recherche : peut-on identifier le graphe causal sous-jacent à ces 300 variables de façon robuste, sans tests exponentiels, et avec des méthodes non linéaires ?

- 1 Contexte et enjeux
- 2 État de l'art
- 3 Objectifs
- 4 Niveau Micro
- 5 Niveau Macro
- 6 Perspectives
- 7 Conclusion

Formalisme de Pearl


Un SCM $\mathcal{M} = \langle \mathbf{U}, \mathbf{V}, \mathcal{F} \rangle$ encode les mécanismes causaux :

$$V_i := f_i(\text{Pa}(V_i), U_i), \quad i = 1, \dots, p$$

- $\mathbf{U}$: bruits exogènes (non observés)
- $\mathbf{V}$: variables endogènes observées
- $\mathcal{F}$: fonctions structurelles, le mécanisme

Hypothèses fondamentales

- **Acyclicité** : le graphe $\mathcal{G}$ est un DAG
- **Markovianité** : $V_i \perp\!\!\!\perp \text{Non-desc}(V_i) \mid \text{Pa}(V_i)$
- **Fidélité** : toute indépendance observée est expliquée par une d-séparation dans $\mathcal{G}$



Exemple de

DAG ; V_1 est la source (racine).

Problème fondamental : Le nombre de DAGs sur p croît super-exponentiellement. Pour $p = 10$: déjà $\approx 4 \times 10^{18}$ DAGs possibles. L'espace de recherche est inaccessible par force brute.

Trois grandes familles de réponses

- 1 **Tester les indépendances** (PC, FCI Spirtes et al., 2000)
Supprimer les arêtes via des tests statistiques.
Explose combinatoirement ; aveugle aux non-linéarités.
- 2 **Optimiser un score** (GES Chickering, 2002 ; NOTEARS Zheng et al., 2018)
Chercher le DAG qui explique le mieux les données.
Suppose souvent la linéarité ; reste coûteux.
- 3 **Asymétrie des résidus** (LiNGAM Shimizu et al., 2006)
Cause et effet laissent des signatures différentes.
Hypothèses fortes : bruit non gaussien, modèle additif.

PC / FCI

non-lin. ×, lent

GES / NOTEARS

linéaire, lent

LiNGAM

hypoth. fortes

Notre approche : asymétrie des résidus, scalable
+ non-linéaire.

- 1 Contexte et enjeux
- 2 État de l'art
- 3 Objectifs**
- 4 Niveau Micro
- 5 Niveau Macro
- 6 Perspectives
- 7 Conclusion

Niveau micro : existence et orientation d'une arête

① Tests d'indépendance

Pearson, MI-KSG, HSIC : détecter si une arête existe.

② Explicabilité (XAI)

SHAP, LASSO : orienter l'arête une fois détectée.

Question de recherche :

Comment concevoir des méthodes de découverte causale **robustes**, **interprétables** et **scalables** pour des données de grande dimension hétérogènes ?

Niveau macro : graphe global

③ Scalabilité

Clustering causal pour réduire $p = 300 \rightarrow K \approx 15$.

④ Découverte causale robuste

Algorithme REX + bootstrap + extension REX-HSIC.

Contexte institutionnel

- Laboratoire : **LISN** (Paris-Saclay)
- Encadrante : Johanne Cohen
- Données : Universidade de São Paulo, Brésil (Cordeiro, Braghetto)


- 1 Contexte et enjeux
- 2 État de l'art
- 3 Objectifs
- 4 Niveau Micro**
- 5 Niveau Macro
- 6 Perspectives
- 7 Conclusion

Trois tests comparés


- 1 **Pearson** : corrélation linéaire, $\mathcal{O}(n)$.
Échoue si $Y = X^2 + \varepsilon : \hat{r} \xrightarrow{P} 0$ même si $X \not\perp\!\!\!\perp Y$.
- 2 **MI-KSG** : estimateur k -plus proches voisins, $\mathcal{O}(n \log n)$.
Capture toute dépendance ; biais $\mathcal{O}(1/n)$ sur petits échantillons.
- 3 **HSIC** : noyaux dans RKHS, $\mathcal{O}(n^2)$.
 $\text{HSIC}(X, Y) = 0 \Leftrightarrow X \perp\!\!\!\perp Y$ pour k caractéristique (RBF, Laplace).

Critères d'évaluation

- Puissance (détection de vraies dépendances)
- Temps de calcul et scalabilité
- Robustesse au bruit additif



Tests pour différentes structures




Comment lire ce graphique

P-valeur : probabilité d'observer un résultat aussi extrême si les variables étaient indépendantes.
Petite p-valeur $\Rightarrow$ on rejette l'indépendance.

Ce qu'on observe

- Pearson détecte uniquement les relations **linéaires**.
- HSIC (RBF/Laplace) détecte toutes les structures, y compris quadratiques, sinusoïdales, circulaires.
- MI-KSG est robuste mais plus lent.

Courbe de puissance : dépendance quadratique faible




$(Y = 0.3X^2 + \varepsilon)$ Pearson reste à plat (aveugle à la courbure).

Intuition

Dans un modèle prédictif optimal $f \approx \mathbb{E}[Y \mid \mathbf{V}]$, si la contribution de X_j est **systématiquement nulle** pour toutes les instances, alors X_j n'apporte rien une fois les autres variables connues.

Implémentations : SHAP, LASSO, Ridge.



Conjecture : Asymétrie causale (SHAP)

La contribution de X dans le modèle de Y diffère de celle de Y dans le modèle de X :

$$\phi^{Y \leftarrow X} \neq \phi^{X \leftarrow Y}$$

Exploitable pour **orienter** les arêtes du DAG.

Limite

SHAP peu fiable si deux variables sont très corrélées (IN_INTERNET / IN_LABO) : importance distribuée artificiellement.

- 1 Contexte et enjeux
- 2 État de l'art
- 3 Objectifs
- 4 Niveau Micro
- 5 Niveau Macro**
- 6 Perspectives
- 7 Conclusion


Pourquoi réduire la dimension ?

Sans réduction, appliquer un algo directement sur $p = 300$ est impossible : des années de calcul sur une machine standard

Idée : d'abord regrouper les variables proches, puis chercher le graphe causal entre groupes.

Piste à explorer : Clustering causal (Anand et al., 2023)

- ❶ Distance d'indépendance par paires (HSIC normalisé)
- ❷ Clustering hiérarchique $\rightarrow K \approx 15$ groupes
- ❸ Représenter chaque groupe par sa PC1
- ❹ Appliquer REX sur les K macro-variables



Principe : asymétrie des résidus

Si X_i est une **racine** (sans parents), alors pour tout X_j :

$$R_{ji} = X_j - \hat{b}_{ji} X_i \perp\!\!\!\perp X_i$$

Le **score de résidus** identifie la racine :

$$s(i) = \sum_{j \neq i} |\text{Corr}(X_i, X_j - \hat{b}_{ji} X_i)|$$

Puis orthogonalisation des variables restantes.

Piste : Extension non linéaire REX-HSIC

$$\tilde{s}(i) = \sum_{j \neq i} \widehat{\text{HSIC}}(X_i, X_j - \hat{f}_{ji}(X_i))$$

$\hat{f}_{ji}$: régression non paramétrique

Résultat sur les données brésiliennes

Sous-ensemble de $p' = 7$ variables clés :

- ❶ IN_ENERGIA_REDE_PUBLICA (source)
- ❷ IN_AGUA_POTAVEL
- ❸ IN_INTERNET
- ❹ IN_LABO_INFORMATICA
- ❺ QT_SALAS_UTILIZADAS
- ❻ QT_DOC_BAS
- ❼ QT_MAT_BAS (feuille)

- 1 Contexte et enjeux
- 2 État de l'art
- 3 Objectifs
- 4 Niveau Micro
- 5 Niveau Macro
- 6 Perspectives**
- 7 Conclusion

Suite du projet de recherche

- **REX-HSIC** : validation expérimentale complète sur les données brésiliennes
- **Séparabilité causale** : formaliser sous quelles conditions les relations inter-clusters se traduisent fidèlement en relations inter-variables
- **Vérifier le graphe** Trouver une façon de vérifier la cohérence du graphe.

Sujet adjacent

Étude connexe de l'explicabilité

Article soumis à la conférence MFCS.

Choix académiques

- **Master 1 Maths** à Sorbonne (distanciel) : mesure, probabilités, optimisation
- **Spécialisation 3A** : dominante MDS, filière Recherche
- **Électifs envisagés** : probabilités avancées, machine learning
- **Objectif long terme** : peut-être une thèse !

Bilan scientifique

- Comparaison rigoureuse de tests d'indépendance : HSIC détecte des dépendances non linéaires invisibles à Pearson.
- Implémentation de REX avec stabilisation bootstrap sur données réelles.
- Conception d'une stratégie de clustering causal scalable pour $p = 300$.
- Première exploration de l'XAI comme proxy d'indépendance.

Compétences développées

- Tests d'indépendance avancés (théorie des noyaux, RKHS)
- Découverte causale à grande échelle
- Analyse expérimentale et benchmarking
- Première expérience de recherche scientifique

Ce projet m'a confirmé l'intérêt d'une carrière en recherche à l'interface des **mathématiques, de la statistique et de l'IA causale**.

- Anand, T.V. et al. (2023). Causal discovery over clusters of variables in Markovian systems. *arXiv*.
- Even-Zohar, C. (2021). Fast rank tests. *J. Computational and Graphical Statistics*.
- Gretton, A. et al. (2007). A kernel statistical test of independence. *NeurIPS*.
- Heskes, T. et al. (2020). Causal Shapley values. *NeurIPS*.
- Hoyer, P. et al. (2009). Nonlinear causal discovery with additive noise models. *NeurIPS*.
- Janzing, D. et al. (2012). Information-geometric approach to inferring causal directions. *Artificial Intelligence*.
- Kraskov, A. et al. (2004). Estimating mutual information. *Physical Review E*.
- Pearl, J. (2009). *Causality : Models, Reasoning, and Inference*. Cambridge University Press.
- Rahimi, A. and Recht, B. (2007). Random features for large-scale kernel machines. *NeurIPS*.
- Ribeiro, M.T. et al. (2016). Why should I trust you ? *ACM SIGKDD*.
- Shapley, L.S. (1953). A value for n -person games. *Contributions to the Theory of Games*.
- Shimizu, S. et al. (2006). A linear non-Gaussian acyclic model. *JMLR*.
- Spirtes, P. et al. (2000). *Causation, Prediction, and Search*. MIT Press.
- Tibshirani, R. (1996). Regression shrinkage via the lasso. *JRSS-B*.
- Zheng, X. et al. (2018). DAGs with NO TEARS. *NeurIPS*.

Pourquoi $\|C_{XY}\|_{\text{HS}}^2 = 0 \Leftrightarrow XY$?

$C_{XY} = 0$ signifie : pour tout $f \in \mathcal{H}_X$, $g \in \mathcal{H}_Y$:

$$\mathbb{E}[f(X)g(Y)] = \mathbb{E}[f(X)]\mathbb{E}[g(Y)]$$

Si k_X est **caractéristique**, $\mathcal{H}_X$ est dense dans $C_0(\mathcal{X})$.
Par un argument de classe monotone, l'égalité s'étend à toutes les fonctions mesurables bornées
 $\Rightarrow \mathbb{P}_{XY} = \mathbb{P}_X \otimes \mathbb{P}_Y$.

Sans caractérisation : $\mathcal{H}_X$ trop pauvre, indépendance seulement dans $\mathcal{H}_X$.

Préfacteur $(n-1)^{-2}$

L'estimateur $\frac{1}{(n-1)^2} \text{Tr}(K_X H K_Y H)$ est une **approximation biaisée** (biais $\mathcal{O}(1/n)$).

Vitesse de convergence

$$\widehat{\text{HSIC}} - \text{HSIC} = \mathcal{O}_p\left(\frac{1}{\sqrt{n}}\right)$$

Test par permutation vs approximation Gamma

L'approximation Gamma est **asymptotique** et requiert l'estimation des moments de la distribution nulle. Sur petits échantillons ou noyaux complexes, elle est imprécise.

Le test par permutation est **exact au niveau** α par construction, pour tout n .

Règle de la médiane pour σ

La validation croisée est **circulaire** dans ce contexte : le critère naturel pour choisir σ serait la puissance du test, mais maximiser la puissance à partir des données invalide les p-valeurs (sur-ajustement).

La médiane $\hat{\sigma} = \text{median}(\{\|x_i - x_j\|\})$ place σ à l'échelle typique des distances. Elle évite :

- σ trop grand : noyau quasi-constant (HSIC ≈ 0 partout)
- σ trop petit : seuls les points identiques ont noyau non nul

Approximation Nyström Rahimi & Recht, 2007

Pour $n = 220\,000$, matrice de Gram ≈ 296 Go : impossible en mémoire.

Nyström : sélectionner $m \ll n$ points représentatifs, approximer :

$$K \approx K_{nm}(K_{mm})^{-1/2}(K_{nm})^\top$$

Complexité : $\mathcal{O}(nm)$ au lieu de $\mathcal{O}(n^2)$.

Random Fourier Features : pour noyaux shift-invariants, approximer $k(x, x') \approx z(x)^\top z(x')$ avec $z(x) \in \mathbb{R}^m$. Même complexité, théorie plus propre.

En pratique : sous-échantillonnage $n' = 5\,000$ suffisant pour nos données.


D'où vient le biais $\mathcal{O}(k/n)$?

L'estimateur KSG repose sur la méthode k -NN de Kozachenko-Leonenko pour l'entropie. Chaque terme $\psi(n_x(i) + 1)$ estime la log-densité locale à partir du volume de la boule de rayon $\epsilon_i/2$.

Ce volume dépend de la densité **locale**, qui varie à l'intérieur de la boule $\Rightarrow$ biais d'ordre $\mathcal{O}(k/n)$.

La correction de KSG (utiliser ϵ_i dans l'espace conjoint, $n_x(i)$ dans les marges) réduit ce biais mais ne l'annule pas.

Choix de k : compromis biais-variance



Choix optimal asymptotique : $k = \lfloor n^{2/5} \rfloor$.

En pratique : $k \in \{3, 5, 10\}$, ou agréger sur plusieurs k .

Bruits corrélés ou modèle non linéaire

Bruits corrélés : la preuve de cohérence s'effondre.

$\text{Cov}(U_i, U_j) \neq 0$ implique que R_{ji} peut être corrélé avec X_i même si X_i est une racine $\Rightarrow$ REX identifie une fausse racine.

Non-linéarité : OLS donne un résidu qui contient la composante non linéaire. Selon le cas :

- La corrélation résiduelle peut être masquée (fausse indépendance)
- Ou amplifiée (fausse dépendance)

$\Rightarrow$ motivation directe de **REX-HSIC** Hoyer et al., 2009.

Pourquoi l'orthogonalisation est nécessaire

Sans orthogonalisation, après avoir identifié V_1 comme racine, les scores $s(V_2)$ et $s(V_3)$ contiennent encore l'influence de V_1 .

Exemple : $V_1 \rightarrow V_2 \rightarrow V_3$. Sans orthogonalisation, V_3 pourrait sembler plus indépendante que V_2 à cause de la médiation.

L'orthogonalisation projette les variables sur le sous-espace orthogonal à V_1 , permettant de trouver la racine du **sous-graphe résiduel**.

PC1 et structure causale interne

Si le cluster contient $V_1 \rightarrow V_2 \rightarrow V_3$, la PC1 est une combinaison linéaire $\alpha V_1 + \beta V_2 + \gamma V_3$ qui **mélange cause et effets** dans un seul vecteur.

L'information sur la direction causale interne est perdue.

La PC1 est un bon résumé de la **variance commune**, pas de la structure causale.

Séparabilité causale : énoncé formel

Soient $\mathcal{C}_1, \dots, \mathcal{C}_K$ les clusters, $\tilde{V}_k = \text{PC}_1(\mathcal{C}_k)$.

Propriété recherchée :

$\tilde{V}_k \rightarrow \tilde{V}_l$ dans le DAG estimé

$\Updownarrow$ (sous conditions $\mathcal{C}$)

$\exists V_i \in \mathcal{C}_k, V_j \in \mathcal{C}_l : V_i \rightarrow V_j$ dans $\mathcal{G}$

La question ouverte est de caractériser $\mathcal{C}$: conditions sur $\mathcal{G}$, sur les coefficients structurels, et sur la procédure de clustering.

Axiome d'efficience et interprétation causale

$\sum_j \phi_j = f(x) - \mathbb{E}[f]$: la totalité de l'écart de la prédiction par rapport à la moyenne est distribuée entre les variables.

Force : les contributions somment à quelque chose d'interprétable.

Limite causale : si X_j et X_k sont corrélés, la répartition entre eux est arbitraire. ϕ_j ne peut pas être lu comme "l'effet causal de X_j " : c'est une contribution à la **prédiction**, mélangeant effets directs et indirects.

Les Causal Shapley Values Heskens et al., 2020 corrigent cela en remplaçant $\mathbb{E}[\cdot \mid X_S]$ par $\mathbb{E}[\cdot \mid \text{do}(X_S)]$.

Complexité 2^p et KernelSHAP

La formule de Shapley somme sur tous les sous-ensembles $S \subseteq N \setminus \{j\}$: 2^{p-1} coalitions par variable, soit $p \cdot 2^{p-1}$ évaluations de f au total.

KernelSHAP est approximatif : il estime les valeurs de Shapley par régression pondérée sur un échantillon de k coalitions aléatoires, avec un noyau de pondération dérivé de la formule de Shapley.

Complexité : $\mathcal{O}(kp)$ pour k coalitions.

L'approximation converge vers les vraies valeurs quand $k \rightarrow \infty$, avec un **biais non nul** pour k fini.